

機械学習による日本の窃盗事案における量刑判断構造の解明

—TF-IDF特徴量とSHAP値・Integrated Gradientsを用いた判決文テキストの計量分析—

貞村真宏¹・向井智哉²・綿村英一郎¹

¹大阪大学大学院人間科学研究科 ²福山大学人間文化学部心理学科

日本犯罪心理学会 第64回大会 2026年9月19日（土）11:20～ 東北大学川内南キャンパス 文科系総合講義棟 第3小講義室
（口頭発表（一般）Ⅰ「処遇」・演題1-5・受付PR0047）

問題と目的

- ・日本の量刑研究＝法解釈学的分析・少数事例の検討が中心。実証研究も事前定義変数の人手コーディングに依拠（変数選択バイアス・認知的制約）
- ・国際的にはNLP/MLによる計算論的量刑研究が中国・ニュージーランド・欧州で進展
- ・日本の判決文NLP/ML研究は引用構造の分析等が先行（東大・久野研）／量刑理由の福祉言説を扱った公刊研究は確認できていない
- ・目的：(1) 判決文テキストからの量刑予測可能性の評価 (2) SHAP値による駆動語彙の同定 (3) 福祉的支援語彙のモデル内での位置の検討

データ：収集の実態も含めて報告

- ・ Westlaw Japanから窃盗関連の全文検索クエリで収集した刑事判決文（一意1,954件・二重取得48組を除去）
- ・ 全文クエリ由来の不均一性を監査で確認：真窃盗主犯は約17%／判決年1958–2026年（想定は2010–2023年）／約3.5%が高裁等＝第一審地裁に限らない
 - データベースは「法的に注目すべき事案」を返す＝日常実務の標本ではない
- ・ 真窃盗サブセットでも判別性能は維持（頑健性確認済み）

方法：3層のエビデンス

- ・ 量刑理由セクションを抽出 → MeCab (UniDic) でトークン化 → TF-IDF 5,000次元
- ・ 前科数を加えた5,001次元 → L1正則化ロジスティック回帰（実刑/執行猶予・10分割層化交差検証） → SHAP値
 - 年齢欄は提出後の監査（2026年9月）で、被告人以外（被害者等）の年齢を多く含むと判明＝除外し線形側を再導出（テキストのみAUC 0.901・前科数を加えて0.925）
- ・ 日本語事前学習済みBERT (tohoku-nlp/bert-base-japanese-v3) を同一分割でファインチューニング（4シードで安定性確認）
- ・ ニューラルモデルの解釈＝Integrated Gradients（3分割） → SHAP・BERT・IGの3層エビデンスを統合

結果① 量刑は判決文から高度に予測可能

- ・ ベースライン AUC=0.925 (テキストのみ0.901) / BERT AUC=0.947
- ・ SHAP最重要因子=前科数 ($|SHAP|=0.331$ ・実刑方向)
- ・ 第2～4位は罪種・被害に関わる語 (殺害・被害・強盗)
- ・ 年齢欄は除外 (提出後の監査で被害者等の年齢と判明・発表論文集の「第4位・執行猶予方向」は撤回)
 - 前科による厳罰化・罪種の重大性という量刑上の考慮要素を, モデルは事前知識なしにテキストから再現

結果② 福祉的支援語彙は判断境界上にある

- ・ 事前定義した福祉的支援語彙59語のうち14語がSHAP重要度上位10%（期待値の2.4倍）
- ・ BERTのIG attribution audit：福祉的支援語彙は非福祉語彙の1.50–2.36倍のattribution magnitude（判決単位クラスタでも比CIは1を跨がず：統合1.85[1.60–2.10]）
- ・ top-500順位への集中度は2.50–5.37倍（平均3.51倍）
 - 線形・神経の両モデルで一貫＝表現形式のアーティファクトではない

結果③ 効果方向は二分している

- ・効果方向（学習係数の符号）＝LIが選んだ26語のうち執行猶予方向17語／実刑方向9語（33語は未選択）
- ・執行猶予方向の例：更生・保護観察・監督
- ・実刑方向の例：社会復帰・施設（「社会復帰は困難」等の否定的文脈が示唆される・探索的）
 - － 支援があること一般ではなく，どの語で・どう語られるかが量刑の向きを分ける（語単位の読みは探索的）

考察

- ・ MLモデルは前科による厳罰化・罪種の重大性という量刑上の考慮要素をテキストから再現した
- ・ 判決前調査（PSI）制度がない日本でも，裁判官は量刑理由の中で福祉情報に言及している＝エビデンスに基づく司法実務への示唆
- ・ MLモデルは福祉的支援語彙の双方向性をそのまま学習しうる → 仮にMLを量刑判断の支援に用いるならば，公平性監査には語単位まで分解した解釈可能性（term-resolved interpretability）が必要
 - 大会テーマ「司法・犯罪心理学における”エビデンスに基づく実践を問う”」への貢献

まとめ

- ・ ①量刑理由を対象とする判決文NLP/ML研究（同種の公刊研究は未確認）＝AUC 0.925/0.947で高い予測可能性（他法域の知見と整合）
- ・ ②福祉的支援語彙は判断境界上に集中（14/59語・2.4倍／IG 1.50–2.36倍・判決単位でも頑健）
- ・ ③効果方向は二分（係数符号で猶予17語/実刑9語）＝語られ方が向きを分ける（語単位・下位分類は探索的）
- ・ コード・語彙リスト・分割は論文公表時に公開（再現可能性）／データ来歴の限界も開示
- ・ ご質問・ご指導をお願いいたします